

Evaluación de un Modelo de Machine Learning con Integración de Bases de Datos

Sebastià Porta Bentzen

IA Developer + Certificación Azure / Proyecto Módulo 6

24 de abril de 2026

Introducción

El objetivo de este trabajo es evaluar el rendimiento de diferentes modelos de Machine Learning mediante un flujo completo de datos que integra bases de datos, procesamiento en Python y visualización en Power BI. Este enfoque permite simular un entorno real de trabajo, en el que los datos no se utilizan de forma aislada, sino que forman parte de un pipeline estructurado desde su almacenamiento hasta su análisis final.

En este proyecto se ha trabajado con modelos de regresión, ya que la variable objetivo es numérica. Concretamente, se ha intentado predecir el número total de horas de sueño (`total_sleep`) a partir de distintas variables biológicas relacionadas con diferentes especies de mamíferos.

El uso de bases de datos es fundamental en este contexto, ya que permite almacenar, estructurar y consultar los datos de forma eficiente. En este caso, se ha utilizado SQLite por su simplicidad y facilidad de integración en entornos locales, siendo una solución adecuada para prototipos y proyectos de análisis de datos. Esto facilita su posterior integración con herramientas de análisis y modelos de inteligencia artificial, garantizando un flujo de trabajo más robusto y escalable.

Descripción del conjunto de datos y su almacenamiento

El dataset utilizado contiene información sobre diferentes especies de mamíferos y sus características biológicas relacionadas con el sueño. Está compuesto por 62 registros y 8 variables.

Entre las variables más relevantes se encuentran:

- body_weight
- brain_weight
- max_life_span
- gestation_time
- predation_index
- sleep_exposure_index
- danger_index
- total_sleep (variable objetivo)

Para la gestión de los datos se ha utilizado una base de datos de tipo SQL, concretamente SQLite. Se ha creado una base de datos denominada `sleep_data.db`, en la cual se ha almacenado el dataset en una tabla llamada `sleep_data`.

Esto ha permitido simular un flujo real de trabajo, donde los datos se almacenan en una base de datos y posteriormente se consultan para ser utilizados en modelos de Machine Learning.

Ejemplo de consulta SQL utilizada:

```
SELECT * FROM sleep_data;
```

Implementación del modelo de Machine Learning

Para el análisis se han utilizado tres modelos de regresión:

- Regresión Lineal (Linear Regression)
- Árbol de Decisión (Decision Tree Regressor)
- Bosque Aleatorio (Random Forest Regressor)

Antes del entrenamiento de los modelos, se ha realizado un proceso de preprocesamiento de los datos que ha incluido:

- Sustitución de valores no válidos ("?", " ") por valores nulos
- Conversión de variables a tipo numérico
- Imputación de valores nulos mediante la mediana
- División del dataset en conjunto de entrenamiento (80%) y prueba (20%)

Los datos han sido extraídos desde la base de datos SQLite mediante consultas SQL y posteriormente utilizados en Python para el entrenamiento de los modelos.

Para evaluar el rendimiento de los modelos se han utilizado las siguientes métricas:

- **MSE (Mean Squared Error):** mide el error del modelo
 - **R² (coeficiente de determinación):** mide la capacidad explicativa del modelo
-

Evaluación del modelo y visualización

Gráfico de regresión

Se ha representado un gráfico de dispersión que muestra la relación entre los valores reales y los valores predichos por el modelo (Decision Tree).

En este gráfico se observa una tendencia positiva, lo que indica que el modelo es capaz de captar parcialmente la relación entre las variables. No obstante, existe cierta dispersión, lo que refleja que el modelo no es completamente preciso.

Para mejorar la visualización, se ha eliminado un valor atípico que distorsionaba la escala del gráfico.

Comparación de modelos

Se han creado gráficos de barras para comparar el rendimiento de los distintos modelos en base a las métricas MSE y R^2 .

Los resultados obtenidos han sido los siguientes:

- **Decision Tree:** mejor rendimiento (menor MSE y mayor $R^2 \approx 0.48$)
- **Random Forest:** rendimiento intermedio (R^2 cercano a 0)
- **Linear Regression:** peor rendimiento (R^2 negativo)

Estos resultados indican que el modelo de árbol de decisión es el más adecuado para este dataset.

Visualización en Power BI

Se ha utilizado Power BI para la visualización de los resultados, importando los datos desde archivos CSV generados a partir del modelo entrenado en Python.

En el dashboard se han creado diferentes visualizaciones con objetivos específicos:

- Un gráfico de dispersión que permite comparar los valores reales frente a los valores predichos, facilitando la identificación de desviaciones y patrones en el comportamiento del modelo.
- Gráficos de barras que muestran las métricas de rendimiento (MSE y R^2) para cada modelo, lo que permite realizar una comparación directa y visual de su rendimiento.
- Una tabla resumen que recoge las métricas principales, permitiendo un análisis más detallado y preciso de los resultados obtenidos.

Además, se han incorporado elementos de interactividad como segmentadores, que permiten explorar los datos de forma dinámica. El uso de Power BI no solo mejora la presentación de los resultados, sino que también facilita su interpretación, permitiendo detectar patrones y evaluar el rendimiento del modelo de manera más intuitiva.

Conclusiones y reflexión final

- A partir de los resultados obtenidos, se puede concluir que el modelo de árbol de decisión ha sido el que ha ofrecido un mejor rendimiento. Este modelo presenta el menor error ($MSE \approx 4.29$) y la mayor capacidad explicativa ($R^2 \approx 0.48$), lo que indica que es capaz de captar de forma razonable la relación entre las variables del dataset. Este comportamiento se debe principalmente a su capacidad para modelar relaciones no lineales, a diferencia de la regresión lineal, que ha mostrado un rendimiento claramente insuficiente con un R^2 negativo. El modelo Random Forest ha obtenido resultados intermedios, lo que sugiere que, sin un ajuste de hiperparámetros adecuado, no logra superar al árbol de decisión en este caso.
- En cuanto al uso de la base de datos, su papel ha sido clave dentro del flujo de trabajo. Aunque no influye directamente en el rendimiento del modelo desde un punto de vista matemático, sí mejora significativamente la organización, almacenamiento y acceso a los datos. La utilización de SQLite ha permitido simular un entorno real en el que los datos se almacenan en un sistema estructurado y se consultan mediante SQL antes de ser utilizados en el entrenamiento del modelo, aportando robustez, trazabilidad y escalabilidad al proceso.
- No obstante, el proyecto presenta ciertas limitaciones. El tamaño reducido del dataset (62 registros) limita la capacidad de generalización de los modelos, lo que puede afectar a la fiabilidad de los resultados. Además, el uso de un árbol de decisión conlleva un riesgo de sobreajuste, especialmente en datasets pequeños, por lo que sus buenos resultados deben interpretarse con cautela.
- Como posibles mejoras futuras, se podrían implementar varias estrategias. En primer lugar, sería recomendable trabajar con un conjunto de datos más amplio para mejorar la capacidad predictiva del modelo. También sería interesante aplicar técnicas de validación cruzada para obtener evaluaciones más robustas, así como ajustar los hiperparámetros de los modelos, especialmente en el caso del Random Forest. Por último, se podrían explorar modelos más avanzados o realizar ingeniería de características (feature engineering) para mejorar el rendimiento general del sistema.